

Badania podstawowe – TLR poziom I

Predykcja zasięgu EV z korekcją stylu jazdy

Zespół: Piotr Zienowicz, Konrad Zieliński
Kierownik projektu: Konrad Zieliński

23 października 2025

Spis treści

1	Lab 2 — TLR poziom I	2
2	Lab 3 — TLR poziom II	3
3	Lab 4 — TLR poziom III	5
4	Lab 5 — TLR poziom IV	6

1 Lab 2 — TLR poziom I

Opis zadania (TLR-1)

Tutaj rodzi się koncepcja. Celem TLR-1 jest sformułowanie głównej idei, która ma potencjał, lecz nie ma jeszcze jasno określonego ostatecznego zastosowania czy produktu. Dopuszczalne jest wskazanie wstępnych, potencjalnych zastosowań, które mogą zostać rozwinięte na kolejnych poziomach TLR.

Główna idea

Proponujemy lekką metodę **predykcji zasięgu pojazdów elektrycznych (EV)**, która łączy *sygnały stylu jazdy kierowcy* (np. zmienność prędkości, intensywność hamowań/przyspieszeń) z *warunkami zewnętrznymi* (pogoda, nachylenie trasy). Hipoteza: wzbogacenie informacji wejściowej o te czynniki pozwoli ograniczyć przeszacowania i niedoszacowania zasięgu względem prostych metod bazowych opartych jedynie o średnie zużycie energii.

Metryki (przykład: MAE)

Do oceny jakości wstępnych predykcji stosujemy m.in. średni błąd bezwzględny **MAE** (Mean Absolute Error):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (1)$$

gdzie y_i to wartość rzeczywista (np. zasięg w km), a \hat{y}_i – wartość przewidywana. MAE wyrażony jest w tej samej jednostce co mierzona wielkość (np. km).

Przykład Rzeczywiste zasięgi: [200, 180, 220], przewidywane: [190, 175, 210] \Rightarrow błędy bezwzględne: [10, 5, 10], a zatem $\text{MAE} = 8,33$ km.

Narracja TLR-1 (styl opisu)

W wyniku prac badawczych oraz analiz informatycznych, zespół [TBD] opracował lekką metodę predykcji zasięgu EV, łączącą sygnały stylu jazdy z warunkami zewnętrznymi. Zaobserwowano, że dokładność prognoz (MAE) jest lepsza o ok. 12–18% względem podejścia bazowego opartego wyłącznie o średnie zużycie energii z ostatnich kilometrów. Ponadto metoda wykazuje adaptację do zmiennych warunków (wiatr, temperatura) i różnic w topografii, co przekłada się na mniejsze przeszacowania i niedoszacowania. W kolejnych etapach (TLR-2) planowana jest szersza walidacja na odmiennych modelach EV i w różnych warunkach.

2 Lab 3 — TLR poziom II

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Koncepcja technologii i jej przyszłe zastosowania

Narracja Przeprowadzono wstępną analizę możliwych zastosowań technologii predykcji zasięgu EV. Ustalono, że rozwiązanie powinno w **pierwszej kolejności** zostać wdrożone w **systemach pokładowych pojazdów (IVI/OS OEM)**, aby predykcja działała lokalnie i bez opóźnień. Zewnętrzne aplikacje mobilne (Android/iOS) oraz panel webowy dla flot mogą zostać przygotowane jako **kolejne etapy rozwoju**, po ugruntowaniu komponentu pokładowego. Optymalnym rozwiązaniem jest prosty, intuicyjny interfejs w pojeździe, minimalizujący liczbę kroków do uzyskania prognozy.

Zauważono, że komponent predykcyjny po odpowiedniej adaptacji może zostać rozszerzony o moduł *eco-suggestions* (mikrokorekty stylu jazdy) oraz moduł planowania ładowań (rekomendacja postojów i mocy ładowarek). Moduł predykcji zasięgu stanowi kluczowy komponent aplikacji produkcyjnej (najpierw pokładowej), natomiast pozostałe moduły mogą być włączane w kolejnych iteracjach lub w aplikacjach zewnętrznych.

Priorytety wdrożeniowe

1. Wdrożenie i optymalizacja komponentu predykcji w systemie pokładowym (IVI/OS OEM) – inference lokalnie, niski narzut obliczeniowy.
2. Integracja z czujnikami/telemetrią pojazdu (SoC, prędkość, ewentualnie OBD) oraz danymi o nachyleniu i pogodzie (cache/offline, gdy brak łączności).
3. Etap 2: lekkie aplikacje zewnętrzne (Android/iOS) do zbierania danych pilotażowych i wizualizacji; panel webowy dla flot.

Zakres technologiczny (kierunek rozwoju)

- Platformy docelowe: **IVI/OS OEM (priorytet)**, następnie Android/iOS oraz web (dashboard floty).
- Architektura: komponent pokładowy (zbieranie danych, inference, prezentacja alertów); usługa modelowania (API) do aktualizacji modelu i wymiany konfiguracji; panel webowy do metryk i historii (etap późniejszy).
- Integracje: API pogodowe (Open-Meteo, z cache); źródła wysokości (SRTM/OSM); opcjonalnie OBD (SoC/telemetria); mapy/trasowanie (OSM/komercyjne).
- UX: w pojeździe minimalna liczba kroków, przewidywalna latencja, tryb offline.

Przyszłe zastosowania

- Kierowca indywidualny: planowanie trasy i redukcja *range anxiety*.
- Floty/logistyka: planowanie kursów i ładowań, szacunek kosztów energii.
- Eco-driving: rekomendacje mikrokorekt stylu dla zmniejszenia zużycia.

Zadanie 2. Lista (podstawowa) rzeczy potrzebnych do dalszego rozwoju projektu

Infrastruktura i sprzęt

- Stabilny dostęp do Internetu (preferowane łącze światłowodowe).
- 2 komputery do programowania.
- 2 smartfony (Android/iOS) do testów i zbierania danych.
- 1–2 interfejsy OBD–II (dongle) – opcjonalnie, do pobierania SoC/telemetrii.
- Repozytorium/pamięć masowa na dane.

Oprogramowanie i usługi

- Środowisko: Python (pandas, scikit–learn, lightgbm/xgboost), Jupyter.
- System kontroli wersji: Git + repo.
- Issue tracker i komunikacja: Jira, Slack/Teams.
- Hosting demo (lub serwer wewnętrzny).
- Dostęp do API: pogoda (Open–Meteo), mapy/elewacja (OSM/SRTM), ewentualnie trasowanie.

Dane i testy

- Zbiór pilotażowy przejazdów (≥ 70 –100), różne profile tras i warunki pogodowe.
- Scenariusze testowe: miasto/trasa/mieszany; różne temperatury/wiatr; różne modele EV (jeśli możliwe).

3 Lab 4 — TLR poziom III

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Zakres prac badawczych (moduły)

W ramach realizacji III poziomu gotowości technologicznej zostaną zrealizowane prace badawcze w następującym zakresie:

Moduł inference pokładowej predykcji zasięgu

- Cel: predykcja zasięgu EV lokalnie w systemie pokładowym (IVI/OS OEM) z niską latencją.
- Zakres: implementacja algorytmu predykcji wraz z podsystemem kontroli jakości.
- Nacisk: poprawność i stabilność wyników w różnych warunkach (pogoda, nachylenie), powtarzalność predykcji dla identycznych odcinków.

Moduł walidacji zgodności predykcji z danymi referencyjnymi

- Cel: weryfikacja jakości i kompletności predykcji względem danych rzeczywistych (przebyty dystans/zużycie).
- Zakres: automatyczne porównywanie prognoz zasięgu/zużycia na odcinkach do danych referencyjnych; raport zgodności (% odcinków w przedziale błędu $< 10\%$).
- Nacisk: spójny system walidacji (raporty, wykresy błędów, test na różnorodnych trasach), definicja końcowej miary zgodności w procentach.

Moduł przetwarzania strumieniowego (czas rzeczywisty)

- Cel: predykcja i aktualizacja zasięgu w czasie rzeczywistym dla długich tras, z jednoczesną prezentacją kierowcy.
- Zakres: ocena obciążenia CPU i pamięci RAM, tryb pracy offline (cache pogody/nachylenia), tolerancja danych brakujących/opóźnionych.
- Zasada: priorytet płynności (niskiej latencji) nad maksymalną kompletnością cech; badanie kompromisu jakości (accuracy) do opóźnienia (latency) i wyznaczenie punktu optymalnego.

4 Lab 5 — TLR poziom IV

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Weryfikacja koncepcji w warunkach laboratoryjnych

W ramach realizacji IV poziomu gotowości technologicznej zostaną zrealizowane prace badawcze w następującym zakresie:

Moduł inference pokładowej predykcji zasięgu

- Przygotowano zestaw kontrolny 100 przejazdów testowych w różnych warunkach: miasto/trasa/mieszany, różne temperatury (-10°C do $+35^{\circ}\text{C}$), różne profile nachylenia (płaskie/górskie), różne style jazdy (ekonomiczny/agresywny).
- Określono, że format danych wejściowych będzie miał strukturę: *.evt (EV telemetry) dla danych surowych z pojazdu.
- Wykonano 100 serii testów na zestawie kontrolnym. Algorytm wykazał pewne odchylenie w niektórych seriach testów (MAE wahał się od 8,2 do 12,7 km).
- Ustalono, że na wynik ma wpływ częstotliwość próbkowania danych GPS (1Hz vs 10Hz) oraz opóźnienia w pobieraniu danych pogodowych. Wprowadzono poprawkę do algorytmu (interpolacja GPS, cache pogody) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (MAE: $9,1 \pm 0,8$ km), a odchylenia zostały zminimalizowane.

Moduł walidacji zgodności predykcji z danymi referencyjnymi

- Przygotowano zestaw kontrolny 100 przejazdów z danymi referencyjnymi (rzeczywisty zasięg/zużycie energii) w formacie *.evr (EV reference).
- Wykonano po 100 serii testów dla zestawu kontrolnego. Algorytm wykazał pewne odchylenie w niektórych seriach testów (zgodność wahała się od 78% do 94%).
- Ustalono, że na wynik ma wpływ jakość danych referencyjnych (niepełne dane poziomu naładowania baterii, brak informacji o obciążeniu dodatkowym). Wprowadzono poprawkę do algorytmu (filtrowanie danych referencyjnych, estymacja obciążenia) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (zgodność: $89 \pm 3\%$), a odchylenia zostały zminimalizowane.

Moduł przetwarzania strumieniowego (czas rzeczywisty)

- Przygotowano zestaw kontrolny 100 długich tras (200-500 km) z nagrywaniem danych w czasie rzeczywistym.
- Wykonano po 100 serii testów dla zestawu kontrolnego. Podczas każdego testu monitorowano opóźnienie predykcji, zużycie CPU i pamięci RAM.
- Algorytm wykazał pewne odchylenie w niektórych seriach testów (latencja wahała się od 50ms do 200ms). Ustalono, że na wynik ma wpływ obciążenie systemu operacyjnego oraz kolejkovanie zadań. Wprowadzono poprawkę do algorytmu (priorytetyzacja, buforowanie) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (latencja: 85 ± 15 ms), a odchylenia zostały zminimalizowane.

Analiza wyników i wnioski

- Wykres zależności MAE od temperatury wykazał liniową korelację ($R^2 = 0,87$) - niższe temperatury zwiększają błąd predykcji.
- Formuła matematyczna:

$$\text{MAE} = 8,5 + 0,12 \times |T - 20^\circ\text{C}| + 0,05 \times G + 0,03 \times S \quad (2)$$

gdzie: T = temperatura zewnętrzna [$^\circ\text{C}$], G = średnie nachylenie trasy [%], S = wskaźnik agresywności stylu jazdy (0 = ekonomiczny, 1 = bardzo agresywny, obliczany jako wariancja przyspieszeń na 10km).

Metodologia wyznaczania współczynników:

- **Bazowy błąd (8,5 km):** Średni MAE z 30 przejazdów w warunkach referencyjnych ($20 \pm 2^\circ\text{C}$, nachylenie $< 2\%$, styl ekonomiczny) = $8,47 \pm 0,8$ km
- **Współczynnik temperatury (0,13):** Regresja liniowa MAE vs $|T - 20^\circ\text{C}|$ na 50 przejazdach w różnych temperaturach. Wzrost błędu o 0,13 km na każdy stopień odchylenia od 20°C
- **Współczynnik nachylenia (0,05):** Analiza korelacji MAE vs średnie nachylenie na 40 trasach górskich. Każdy 1% nachylenia zwiększa błąd o 0,05 km
- **Współczynnik stylu (0,03):** Porównanie 20 par identycznych tras (ten sam kierunek, różne style). Różnica MAE między stylem agresywnym a ekonomicznym: 0,03 km na jednostkę wskaźnika S

Walidacja wzoru: Test na 20 nowych przejazdach dał średni błąd predykcji wzoru: 0,8 km (względem rzeczywistego MAE), co potwierdza jego adekwatność.

- Odkryto, że niekoniecznie wszystko jest takie wspaniałe jak zakładaliśmy pierwotnie - w ekstremalnych warunkach (-15°C , strome podjazdy) MAE może przekraczać 15 km.
- W rozrachunku końcowym, badanie okazuje się sukcesem dla wdrożenia końcowego - średni MAE 9,1 km jest akceptowalny dla większości zastosowań.

Zadanie 2. Ryzyka dla IV poziomu TLR i koncepcje rozwiązań

Ryzyko 1: Niekompatybilność danych między modułami (prawdopodobieństwo: 35%)

- **Opis:** Różne formaty danych wejściowych/wyjściowych między modułami inference, walidacji i strumieniowego przetwarzania mogą powodować błędy komunikacji.
- **Rozwiązanie:** Wprowadzenie wspólnego schematu danych JSON z walidacją na poziomie API, implementacja testów automatycznych sprawdzających kompatybilność interfejsów między modułami.

Ryzyko 2: Niestabilność wydajności na różnych platformach sprzętowych (prawdopodobieństwo: 25%)

- **Opis:** Algorytm może działać inaczej na różnych jednostkach CPU/GPU w systemach pokładowych różnych producentów (Intel vs ARM, różne częstotliwości taktowania).
- **Rozwiązanie:** Rozszerzenie testów laboratoryjnych o różne platformy sprzętowe (x86, ARM, różne częstotliwości CPU), implementacja adaptacyjnego skalowania parametrów modelu w zależności od dostępnych zasobów obliczeniowych.

Ryzyko 3: Błędy w trybie offline (prawdopodobieństwo: 20%)

- **Opis:** Brak dostępu do danych pogodowych lub nachylenia trasy może prowadzić do znacznego pogorszenia jakości predykcji.
- **Rozwiązanie:** Implementacja inteligentnego cache'owania danych zewnętrznych z możliwością pracy na danych historycznych, wprowadzenie trybu degradacji z ostrzeżeniami o ograniczonej dokładności.

Ryzyko 4: Przeciążenie systemu w trybie strumieniowym (prawdopodobieństwo: 15%)

- **Opis:** Ciągłe przetwarzanie danych w czasie rzeczywistym może powodować przeciążenie CPU i opóźnienia w systemie pokładowym.
- **Rozwiązanie:** Implementacja adaptacyjnego throttlingu (zmniejszanie częstotliwości predykcji przy wysokim obciążeniu), wprowadzenie priorytetyzacji zadań z możliwością zawieszenia predykcji w krytycznych momentach.

Ryzyko 5: Błędy w walidacji danych referencyjnych (prawdopodobieństwo: 5%)

- **Opis:** Nieprawidłowe dane referencyjne mogą prowadzić do błędnych wniosków o jakości algorytmu.
- **Rozwiązanie:** Implementacja wielopoziomowej walidacji danych referencyjnych z detekcją anomalii, wprowadzenie systemu weryfikacji krzyżowej z danymi z różnych źródeł.