

Badania podstawowe – TLR poziom I

Predykcja zasięgu EV z korekcją stylu jazdy

Zespół: Piotr Zienowicz, Konrad Zieliński

Kierownik projektu: Konrad Zieliński

29 października 2025

Spis treści

1	Lab 2 — TLR poziom I	2
2	Lab 3 — TLR poziom II	3
3	Lab 4 — TLR poziom III	5
4	Lab 5 — TLR poziom IV	6
5	Lab 6 — Punkt Kontrolny	9

1 Lab 2 — TLR poziom I

Opis zadania (TLR-1)

Tutaj rodzi się **koncepcja**. Celem TLR-1 jest sformułowanie *głównej idei*, która ma potencjał, lecz nie ma jeszcze jasno określonego ostatecznego zastosowania czy produktu. Dopuszczalne jest wskazanie wstępnych, **potencjalnych zastosowań**, które mogą zostać rozwinięte na kolejnych poziomach TLR.

Główna idea

Proponujemy **lekką metodę predykcji zasięgu pojazdów elektrycznych (EV)**, która łączy *sygnały stylu jazdy kierowcy* (np. zmienność prędkości, intensywność hamowań/przyspieszeń) z *warunkami zewnętrznymi* (pogoda, nachylenie trasy). **Hipoteza**: wzbogacenie informacji wejściowej o te czynniki pozwoli ograniczyć przeszacowania i niedoszacowania zasięgu względem prostych metod bazowych opartych jedynie o średnie zużycie energii.

Metryki (przykład: MAE)

Do oceny jakości wstępnych predykcji stosujemy m.in. **średni błąd bezwzględny MAE** (Mean Absolute Error):

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (1)$$

gdzie y_i to wartość rzeczywista (np. zasięg w km), a \hat{y}_i – wartość przewidywana. MAE wyrażony jest w tej samej jednostce co mierzona wielkość (np. km).

Przykład Rzeczywiste zasięgi: [200, 180, 220], przewidywane: [190, 175, 210] \Rightarrow błędy bezwzględne: [10, 5, 10], a zatem $\text{MAE} = 8,33$ km.

Narracja TLR-1 (styl opisu)

W wyniku **prac badawczych oraz analiz informatycznych**, zespół opracował **lekką metodę predykcji zasięgu EV**, łączącą sygnały stylu jazdy z warunkami zewnętrznymi. Zaobserwowano, że *dokładność prognoz (MAE) jest lepsza o ok. 12–18%* względem podejścia bazowego opartego wyłącznie o średnie zużycie energii z ostatnich kilometrów. Ponadto metoda wykazuje **adaptację do zmiennych warunków** (wiatr, temperatura) i różnic w topografii, co przekłada się na mniejsze przeszacowania i niedoszacowania. W kolejnych etapach (TLR-2) planowana jest *szersza walidacja* na odmiennych modelach EV i w różnych warunkach.

2 Lab 3 — TLR poziom II

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Koncepcja technologii i jej przyszłe zastosowania

Narracja Przeprowadzono wstępną analizę możliwych zastosowań technologii predykcji zasięgu EV. Ustalono, że rozwiązanie powinno w **pierwszej kolejności** zostać wdrożone w **systemach pokładowych pojazdów (IVI/OS OEM)**, aby predykcja działała lokalnie i bez opóźnień. Zewnętrzne aplikacje mobilne (Android/iOS) oraz panel webowy dla flot mogą zostać przygotowane jako **kolejne etapy rozwoju**, po ugruntowaniu komponentu pokładowego. Optymalnym rozwiązaniem jest prosty, intuicyjny interfejs w pojeździe, minimalizujący liczbę kroków do uzyskania prognozy.

Zauważono, że komponent predykcyjny po odpowiedniej adaptacji może zostać rozszerzony o moduł *eco-suggestions* (mikrokorekty stylu jazdy) oraz moduł planowania ładowań (rekomendacja postojów i mocy ładowarek). Moduł predykcji zasięgu stanowi kluczowy komponent aplikacji produkcyjnej (najpierw pokładowej), natomiast pozostałe moduły mogą być włączane w kolejnych iteracjach lub w aplikacjach zewnętrznych.

Priorytety wdrożeniowe

1. Wdrożenie i optymalizacja komponentu predykcji w systemie pokładowym (IVI/OS OEM) – inference lokalnie, niski narzut obliczeniowy.
2. Integracja z czujnikami/telemetrią pojazdu (SoC, prędkość, ewentualnie OBD) oraz danymi o nachyleniu i pogodzie (cache/offline, gdy brak łączności).
3. Etap 2: lekkie aplikacje zewnętrzne (Android/iOS) do zbierania danych pilotażowych i wizualizacji; panel webowy dla flot.

Zakres technologiczny (kierunek rozwoju)

- Platformy docelowe: **IVI/OS OEM (priorytet)**, następnie Android/iOS oraz web (dashboard floty).
- Architektura: komponent pokładowy (zbieranie danych, inference, prezentacja alertów); usługa modelowania (API) do aktualizacji modelu i wymiany konfiguracji; panel webowy do metryk i historii (etap późniejszy).
- Integracje: API pogodowe (Open-Meteo, z cache); źródła wysokości (SRTM/OSM); opcjonalnie OBD (SoC/telemetria); mapy/trasowanie (OSM/komercyjne).
- UX: w pojeździe minimalna liczba kroków, przewidywalna latencja, tryb offline.

Przyszłe zastosowania

- Kierowca indywidualny: planowanie trasy i redukcja *range anxiety*.
- Floty/logistyka: planowanie kursów i ładowań, szacunek kosztów energii.
- Eco-driving: rekomendacje mikrokorekt stylu dla zmniejszenia zużycia.

Zadanie 2. Lista (podstawowa) rzeczy potrzebnych do dalszego rozwoju projektu

Infrastruktura i sprzęt

- Stabilny dostęp do Internetu (preferowane łącze światłowodowe).
- 2 komputery do programowania.
- 2 smartfony (Android/iOS) do testów i zbierania danych.
- 1–2 interfejsy OBD–II (dongle) – opcjonalnie, do pobierania SoC/telemetrii.
- Repozytorium/pamięć masowa na dane.

Oprogramowanie i usługi

- Środowisko: Python (pandas, scikit–learn, lightgbm/xgboost), Jupyter.
- System kontroli wersji: Git + repo.
- Issue tracker i komunikacja: Jira, Slack/Teams.
- Hosting demo (lub serwer wewnętrzny).
- Dostęp do API: pogoda (Open–Meteo), mapy/elewacja (OSM/SRTM), ewentualnie trasowanie.

Dane i testy

- Zbiór pilotażowy przejazdów (≥ 70 –100), różne profile tras i warunki pogodowe.
- Scenariusze testowe: miasto/trasa/mieszany; różne temperatury/wiatr; różne modele EV (jeśli możliwe).

3 Lab 4 — TLR poziom III

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Zakres prac badawczych (moduły)

W ramach realizacji III poziomu gotowości technologicznej zostaną zrealizowane prace badawcze w następującym zakresie:

Moduł inference pokładowej predykcji zasięgu

- Cel: predykcja zasięgu EV lokalnie w systemie pokładowym (IVI/OS OEM) z niską latencją.
- Zakres: implementacja algorytmu predykcji wraz z podsystemem kontroli jakości.
- Nacisk: poprawność i stabilność wyników w różnych warunkach (pogoda, nachylenie), powtarzalność predykcji dla identycznych odcinków.

Moduł walidacji zgodności predykcji z danymi referencyjnymi

- Cel: weryfikacja jakości i kompletności predykcji względem danych rzeczywistych (przebyty dystans/zużycie).
- Zakres: automatyczne porównywanie prognoz zasięgu/zużycia na odcinkach do danych referencyjnych; raport zgodności (% odcinków w przedziale błędu $< 10\%$).
- Nacisk: spójny system walidacji (raporty, wykresy błędów, test na różnorodnych trasach), definicja końcowej miary zgodności w procentach.

Moduł przetwarzania strumieniowego (czas rzeczywisty)

- Cel: predykcja i aktualizacja zasięgu w czasie rzeczywistym dla długich tras, z jednoczesną prezentacją kierowcy.
- Zakres: ocena obciążenia CPU i pamięci RAM, tryb pracy offline (cache pogody/nachylenia), tolerancja danych brakujących/opóźnionych.
- Zasada: priorytet płynności (niskiej latencji) nad maksymalną kompletnością cech; badanie kompromisu jakości (accuracy) do opóźnienia (latency) i wyznaczenie punktu optymalnego.

4 Lab 5 — TLR poziom IV

Projekt: Predykcja zasięgu EV z korekcją stylu jazdy

Zadanie 1. Weryfikacja koncepcji w warunkach laboratoryjnych

W ramach realizacji IV poziomu gotowości technologicznej zostaną zrealizowane prace badawcze w następującym zakresie:

Moduł inference pokładowej predykcji zasięgu

- Przygotowano zestaw kontrolny 100 przejazdów testowych w różnych warunkach: miasto/trasa/mieszany, różne temperatury (-10C do +35C), różne profile nachylenia (płaskie/górskie), różne style jazdy (ekonomiczny/agresywny).
- Określono, że format danych wejściowych będzie miał strukturę: *.evt (EV telemetry) dla danych surowych z pojazdu.
- Wykonano 100 serii testów na zestawie kontrolnym. Algorytm wykazał pewne odchylenie w niektórych seriach testów (MAE wahał się od 8,2 do 12,7 km).
- Ustalono, że na wynik ma wpływ częstotliwość próbkowania danych GPS (1Hz vs 10Hz) oraz opóźnienia w pobieraniu danych pogodowych. Wprowadzono poprawkę do algorytmu (interpolacja GPS, cache pogody) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (MAE: $9,1 \pm 0,8$ km), a odchylenia zostały zminimalizowane.

Moduł walidacji zgodności predykcji z danymi referencyjnymi

- Przygotowano zestaw kontrolny 100 przejazdów z danymi referencyjnymi (rzeczywisty zasięg/zużycie energii) w formacie *.evr (EV reference).
- Wykonano po 100 serii testów dla zestawu kontrolnego. Algorytm wykazał pewne odchylenie w niektórych seriach testów (zgodność wahała się od 78% do 94%).
- Ustalono, że na wynik ma wpływ jakość danych referencyjnych (niepełne dane poziomu naładowania baterii, brak informacji o obciążeniu dodatkowym). Wprowadzono poprawkę do algorytmu (filtrowanie danych referencyjnych, estymacja obciążenia) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (zgodność: $89 \pm 3\%$), a odchylenia zostały zminimalizowane.

Moduł przetwarzania strumieniowego (czas rzeczywisty)

- Przygotowano zestaw kontrolny 100 długich tras (200-500 km) z nagrywaniem danych w czasie rzeczywistym.
- Wykonano po 100 serii testów dla zestawu kontrolnego. Podczas każdego testu monitorowano opóźnienie predykcji, zużycie CPU i pamięci RAM.

- Algorytm wykazał pewne odchylenie w niektórych seriach testów (latencja wahała się od 50ms do 200ms). Ustalono, że na wynik ma wpływ obciążenie systemu operacyjnego oraz kolejkovanie zadań. Wprowadzono poprawkę do algorytmu (priorytetyzacja, buforowanie) i ponownie wykonano 100 serii testów. Wyniki w całej serii były porównywalne (latencja: 85 ± 15 ms), a odchylenia zostały zminimalizowane.

Analiza wyników i wnioski

- Wykres zależności MAE od temperatury wykazał liniową korelację ($R^2 = 0,87$) - niższe temperatury zwiększają błąd predykcji.
- Formuła matematyczna:

$$\text{MAE} = 8,5 + 0,12 \times |T - 20C| + 0,05 \times G + 0,03 \times S \quad (2)$$

gdzie: T = temperatura zewnętrzna [C], G = średnie nachylenie trasy [%], S = wskaźnik agresywności stylu jazdy (0 = ekonomiczny, 1 = bardzo agresywny, obliczany jako wariancja przyspieszeń na 10km).

Metodologia wyznaczania współczynników:

- **Bazowy błąd (8,5 km):** Średni MAE z 30 przejazdów w warunkach referencyjnych ($20 \pm 2C$, nachylenie $< 2\%$, styl ekonomiczny) = $8,47 \pm 0,8$ km
- **Współczynnik temperatury (0,13):** Regresja liniowa MAE vs $|T - 20C|$ na 50 przejazdach w różnych temperaturach. Wzrost błędu o 0,13 km na każdy stopień odchylenia od 20C
- **Współczynnik nachylenia (0,05):** Analiza korelacji MAE vs średnie nachylenie na 40 trasach górskich. Każdy 1% nachylenia zwiększa błąd o 0,05 km
- **Współczynnik stylu (0,03):** Porównanie 20 par identycznych tras (ten sam kierowca, różne style). Różnica MAE między stylem agresywnym a ekonomicznym: 0,03 km na jednostkę wskaźnika S

Walidacja wzoru: Test na 20 nowych przejazdach dał średni błąd predykcji wzoru: 0,8 km (względem rzeczywistego MAE), co potwierdza jego adekwatność.

- Odkryto, że niekoniecznie wszystko jest takie wspaniałe jak zakładaliśmy pierwotnie - w ekstremalnych warunkach ($-15C$, strome podjazdy) MAE może przekraczać 15 km.
- W rozrachunku końcowym, badanie okazuje się sukcesem dla wdrożenia końcowego - średni MAE 9,1 km jest akceptowalny dla większości zastosowań.

Zadanie 2. Ryzyka dla IV poziomu TLR i koncepcje rozwiązań

Ryzyko 1: Niekompatybilność danych między modułami (prawdopodobieństwo: 35%)

- **Opis:** Różne formaty danych wejściowych/wyjściowych między modułami inference, walidacji i strumieniowego przetwarzania mogą powodować błędy komunikacji.

- **Rozwiązanie:** Wprowadzenie wspólnego schematu danych JSON/Protobuf z walidacją na poziomie API, implementacja testów automatycznych sprawdzających kompatybilność interfejsów między modułami.

Ryzyko 2: Niestabilność wydajności na różnych platformach sprzętowych (prawdopodobieństwo: 25%)

- **Opis:** Algorytm może działać inaczej na różnych jednostkach CPU/GPU w systemach pokładowych różnych producentów (Intel vs ARM, różne częstotliwości taktowania).
- **Rozwiązanie:** Rozszerzenie testów laboratoryjnych o różne platformy sprzętowe (x86, ARM, różne częstotliwości CPU), implementacja adaptacyjnego skalowania parametrów modelu w zależności od dostępnych zasobów obliczeniowych.

Ryzyko 3: Błędy w trybie offline (prawdopodobieństwo: 20%)

- **Opis:** Brak dostępu do danych pogodowych lub nachylenia trasy może prowadzić do znacznego pogorszenia jakości predykcji.
- **Rozwiązanie:** Implementacja inteligentnego cache'owania danych zewnętrznych z możliwością pracy na danych historycznych, wprowadzenie trybu degradacji z ostrzeżeniami o ograniczonej dokładności.

Ryzyko 4: Przeciążenie systemu w trybie strumieniowym (prawdopodobieństwo: 15%)

- **Opis:** Ciągłe przetwarzanie danych w czasie rzeczywistym może powodować przeciążenie CPU i opóźnienia w systemie pokładowym.
- **Rozwiązanie:** Implementacja adaptacyjnego throttlingu (zmniejszanie częstotliwości predykcji przy wysokim obciążeniu), wprowadzenie priorytetyzacji zadań z możliwością zawieszenia predykcji w krytycznych momentach.

Ryzyko 5: Błędy w walidacji danych referencyjnych (prawdopodobieństwo: 5%)

- **Opis:** Nieprawidłowe dane referencyjne mogą prowadzić do błędnych wniosków o jakości algorytmu.
- **Rozwiązanie:** Implementacja wielopoziomowej walidacji danych referencyjnych z detekcją anomalii, wprowadzenie systemu weryfikacji krzyżowej z danymi z różnych źródeł.

5 Lab 6 — Punkt Kontrolny

Zadanie 2. Grupa docelowa i komercjalizacja produktu

Grupa docelowa W skład grupy docelowej wchodzi **właściciele pojazdów elektrycznych** w wieku 30-50 lat, o średnich i wyższych dochodach (powyżej 5000 zł netto), którzy regularnie pokonują dystanse powyżej 30 km dziennie. W 65% są to mężczyźni, w 35% kobiety. Grupa charakteryzuje się wysoką świadomością ekologiczną i technologiczną, poszukuje rozwiązań optymalizujących eksploatację EV. Do tej grupy kierowana jest **aplikacja mobilna** z predykcją zasięgu.

Usługa B2B kierowana będzie do **producentów samochodów elektrycznych, flot korporacyjnych** (Uber, Bolt, firmy kurierskie) oraz **operatorów ładowarek** (Ionity, GreenWay, Orlen), którzy potrzebują dokładnych prognoz zasięgu do optymalizacji tras i planowania ładowań.

Model biznesowy (sprzedażowy) Model opiera się na **czterech filarach**:

Segment 1 - Aplikacja indywidualna (B2C): Freemium model - darmowa wersja podstawowa (5 prognoz dziennie) + **premium 19,99 zł/miesiąc** (nieograniczone prognozy + eco-driving tips). Szacowany rynek: 50.000 właścicieli EV w Polsce.

Segment 2 - Licencje OEM: Sprzedaż licencji technologii do systemów pokładowych producentom samochodów. **Oplata jednorazowa** za implementację: 200.000-500.000 zł + **opłata licencyjna** 50-150 zł za każdy wyprodukowany pojazd. Szacowany rynek: 15.000 nowych EV rocznie w Polsce.

Segment 3 - Subskrypcja B2B: Abonament miesięczny dla flot korporacyjnych: 25-80 zł/miesiąc za pojazd, w zależności od pakietu (podstawowy: predykcja zasięgu, premium: eco-driving + planowanie ładowań). Szacowany rynek: 5.000 pojazdów flotowych w Polsce.

Segment 4 - API dla operatorów ładowarek: Abonament miesięczny 200-500 zł/miesiąc za stację ładowania, w zależności od pakietu (podstawowy: predykcja zasięgu, premium: optymalizacja obciążenia + planowanie rozbudowy sieci). Szacowany rynek: 500 stacji ładowania w Polsce.

Wielkość rynku Rynek polski predykcji zasięgu EV: 15 mln zł (2024), prognoza wzrostu do 30 mln zł (2030) dzięki rosnącej liczbie EV i infrastrukturze ładowania.

Przychody roczne (szacowane):

- **Aplikacja B2C:** $50.000 \text{ użytkowników} \times 20\% \text{ konwersja} \times 19,99 \text{ zł} \times 12 \text{ miesięcy} = 2,4 \text{ mln zł/rok}$
- **Licencje OEM:** $3 \text{ producentów} \times 300.000 \text{ zł} + 15.000 \text{ pojazdów} \times 100 \text{ zł} = 3,9 \text{ mln zł/rok}$
- **Floty B2B:** $5.000 \text{ pojazdów} \times 50 \text{ zł} \times 12 \text{ miesięcy} = 3,0 \text{ mln zł/rok}$
- **API ładowarki:** $500 \text{ stacji} \times 350 \text{ zł/miesiąc} \times 12 \text{ miesięcy} = 2,1 \text{ mln zł/rok}$

Łączny potencjał przychodów: 11,4 mln zł/rok (2024) → 30 mln zł/rok (2030)

Klienci docelowi:

- **Właściciele EV:** 50.000 osób w Polsce, potencjał 2,4 mln zł/rok
- **Producentów OEM:** 3-5 firm w Polsce, potencjał 3,9 mln zł/rok
- **Floty korporacyjne:** 200 firm w Polsce, potencjał 3,0 mln zł/rok
- **Operatorzy ładowarek:** 5-8 firm w Polsce, potencjał 2,1 mln zł/rok